Лекция 9

АНАЛИЗ ВРЕМЕННЫХ РЯДОВ (РЯДЫ ДИНАМИКИ)

Ряды динамики и анализ данных

МЕТОДЫ ИНТЕЛЛЕКТУАЛЬНОГО АНАЛИЗА ДАННЫХ

Непосредственное использование данных

(Data Retention)

Выявление и использование закономерностей

(Data Distillation)

Paccyждения на основе анализа прецедентов (Case-based Reasoning)

Алгоритмы типа Lazy-Learning:

- 1) метод «ближайшего соседа»;
- метод к-ближайшего соседа;
- 3) метод NGE и др.

Методы кросстабуляции

(Cross Tabulational Distillation)

- 1) Кросс-табличная визуализация;
- Байесовские сети (Bayesian Networks.
- в т. ч. наивная байесовская классификация;

Методы логической индукции

(Logic Distillation)

- Деревья решений (Decision Trees);
- Индукция правил (Rule Learning).

Методы вывода уравнений

(Equational Distillation)

- 1) Методы статистики
- ряды динамики;
- корреляционнорегрессионный анализ;
- Нейронные cemu (Neural Nets).

Классификация технологических методов ИАД [1]

Ряды динамики. Основные определения

Ряд наблюдений за значениями определенного показателя, упорядоченный в зависимости от возрастающих или убывающих значений другого показателя, называют динамическим рядом, временным рядом, рядом динамики.

Отдельные наблюдения временного ряда называются уровнями этого ряда.

Временные ряды бывают моментные, интервальные и производные.

- Моментные ряды характеризуют значения показателя на определенные моменты времени.
- Интервальные ряды характеризуют значения показателя за определенные интервалы времени.
- Производные ряды получаются из средних или относительных величин показателя.

Временные ряды. Условия прогнозирования

Уровни ряда могут иметь **детерминированные** или **случайные значения**.

Ряд последовательных данных о количестве дней в месяце, квартале, годе являются примерами рядов с детерминированными значениями.

Прогнозированию подвергаются ряды со случайными значениями уровней. Каждый показатель таких рядов может иметь дискретную или непрерывную величину.

•Важное значение для прогнозирования имеет выбор интервалов между соседними уровнями ряда.

При слишком большом интервале времени могут быть упущены некоторые закономерности в динамике показателя. При слишком малом — увеличивается объем вычислений, могут появляться ненужные детали в динамике процесса.

•Важным условием правильного отражения временным рядом реального процесса развития является сопоставимость уровней ряда. Несопоставимость чаще всего встречается в стоимостных характеристиках, изменениях цен, территориальных изменениях, при укрупнении предприятий и др.

Для несопоставимых величин показателя неправомерно проводить прогнозирование.

Временные ряды. Условия для успешного изучения

Для успешного изучения динамики процесса необходимо, чтобы информация была полной, временной ряд имел достаточную длину, отсутствовали пропущенные наблюдения.

•Уровни временных рядов могу иметь аномальные значения.

Появление таких значений может быть вызвано ошибками при сборе, записи или передачи информации. Это ошибки технического порядка или ошибки первого рода.

Однако аномальные значения могут отражать реальные процессы, например, скачок курса доллара и др. Такие аномальные значения относят к ошибкам второго рода, они устранению не подлежат.

Для выявления аномальных уровней временных рядов можно использовать метод Ирвина.

Временные ряды. Выявление аномалий

Метод Ирвина предполагает использование следующей формулы:

$$\lambda_t = \frac{|y_t - y_{t-1}|}{\sigma_y}, t = 1, 2, ..., n$$

где σ_y , среднеквадратическое отклонение временного ряда $y_1, y_2, ..., y_i, y_n$.

$$\sigma_y = \sqrt{\frac{\sum (y_t - \bar{y})^2}{n - 1}}, \ \bar{y} = \frac{\sum y_t}{n}$$

Расчетные значения λ_2 , λ_3 ,... сравниваются с табличными значениями критерия Ирвина λ_{α} , и *если оказываются больше табличных, то соответствующее значение у, уровня ряда считается аномальным*.

Значения критерия Ирвина для уровня значимости $\alpha = 0.05$ приведены в табл. 1.

Таблица 1

n	2	3	10	20	30	50	100
λ _a	2,8	2,3	1,5	1,3	1,2	1,1	1,0

Временные ряды. Выявление тренда

Если во временном ряду проявляется длительная тенденция изменения показателя, то в этом случае говорят, что имеет место *тенденден* тенденция изменения показателя, то в этом случае говорят, что имеет место *тенденден* тенденция изменения показателя, то в этом случае говорят, что имеет место *тенденция* показателя, то в этом случае говорят, что имеет место *тенденция* изменения показателя, то в этом случае говорят, что имеет место *тенденция* изменения показателя, то в этом случае говорят, что имеет место *тенденция* изменения показателя, то в этом случае говорят, что имеет место *тенденция* изменения показателя, то в этом случае говорят, что имеет место *тенденция* изменения показателя, то в этом случае говорят, что имеет место *тенденция* изменения показателя, то в этом случае говорят, что имеет место *тенденция* изменения показателя и показателя и

Пусть дан временной ряд $y_1, y_2, ..., y_i, y_{n_i}$ t = 1, 2, ..., n.

Считают, что значения уровней временных рядов показателей складываются из следующих составляющих (компонент): *тенда, сезонной, циклической и случайной*.

Под трендом понимают изменение, определяющее общее направление развития или основную тенденцию временного ряда. Тренд относят к систематической составляющей долговременного действия. Во временных рядах часто происходят регулярные колебания, которые относятся к периодическим составляющим рядов экономических процессов.

- Если период колебаний не превышает 1 года, то их называют сезонными, более 1 года циклическими составляющими.
- Чаще всего причиной сезонных колебаний являются природные, климатические условия, циклических – демографические циклы др.
- Тренд, сезонная и циклическая составляющая называются регулярными, или систематическими компонентами временного ряда.
- Если из временного ряда удалить регулярную компоненту, то останется *случайная компонента*.

Временные ряды. Выявление тренда

Если временной ряд представлен в виде суммы составляющих компонент, то модель называется *аддитивной*, если в виде произведения, то *мультипликативной* или *смешанного* типа.

```
y_t = u_t + s_t + v_t + e_t — аддитивная форма,
```

- $y_t = u_t s_t v_t e_t$ мультипликативная форма,
- $y_t = u_t s_t v_t + e_t$ смешанная форма,

где y_t — уровни временного ряда;

 u_t — временной тренд;

 s_t — сезонная компонента;

 V_t — циклическая составляющая;

 e_t — случайная компонента.

Временные ряды. Критерий восходящих серий

Прогнозирование временных рядов целесообразно начинать с построения графика исследуемого показателя. Однако в нем не всегда прослеживается присутствие тренда. Поэтому в этих случаях необходимо выяснить, существует ли тенденция во временном ряду или она отсутствует.

Дан временной ряд:
$$y_1, y_2, ..., y_i, y_n, t = 1, 2, ..., n$$
.

Рассмотрим *критерий «восходящих и нисходящих» серий,* согласно которому тенденция определяется по следующему алгоритму.

1. Для исследуемого временного ряда определяется последовательность знаков, исходя из условий

+, если
$$y_{t+1} - y_t > 0$$
,

- , если
$$y_{t+1} - y_t < 0$$
.

Временные ряды. Критерий восходящих серий

При этом, если последующее наблюдение равно предыдущему, то учитывается только одно наблюдение.

- **2.** Подсчитывается число серий v(n). Под серией понимается последовательность подряд расположенных плюсов или минусов, причем один плюс или один минус считается серией.
- **3.** Определяется протяженность самой длинной серии $l_{\max}\left(n\right)$
- **4.** По табл. 2 находится значение l(n).

Таблица 2

Длина ряда (n)	n<=26	26 <n<=153< th=""><th>153<n<=170< th=""></n<=170<></th></n<=153<>	153 <n<=170< th=""></n<=170<>
Значение <i>I(п)</i>	5	6	7

5. Если нарушается хотя бы одно из следующих неравенств, то гипотеза об отсутствии тренда отвергается с доверительной вероятностью 0,95.

$$v(n) > \left[(2n-1)/3 - 1,96\sqrt{16n - 29/90} \right], \ l_{max}(n) \le l(n)$$

Временные ряды. Критерий восходящих серий

При этом, если последующее наблюдение равно предыдущему, то учитывается только одно наблюдение.

- **2.** Подсчитывается число серий v(n). Под серией понимается последовательность подряд расположенных плюсов или минусов, причем один плюс или один минус считается серией.
- **3.** Определяется протяженность самой длинной серии $l_{\max}\left(n\right)$
- **4.** По табл. 2 находится значение l(n).

Таблица 2

Длина ряда (n)	n<=26	26 <n<=153< th=""><th>153<n<=170< th=""></n<=170<></th></n<=153<>	153 <n<=170< th=""></n<=170<>
Значение <i>I(п)</i>	5	6	7

5. Если нарушается хотя бы одно из следующих неравенств, то гипотеза об отсутствии тренда отвергается с доверительной вероятностью 0,95.

$$v(n) > \left[(2n-1)/3 - 1.96\sqrt{16n - 29/90} \right], \ l_{max}(n) \le l(n)$$

Анализ временных рядов объединяет методы изучения временных рядов, как пытающиеся понять природу точек данных (откуда они взялись? что их породило?), так и пытающиеся построить прогноз.

Прогнозирование временных рядов заключается в построении модели для предсказания будущих событий основываясь на известных событий прошлого, предсказания будущих данных до того как они будут измерены. Типичный пример — предсказание цены открытия биржи основываясь на предыдущей её деятельности.

Понятие анализ временных рядов используется для того, чтобы

- отделить эту задачу от в первую очередь от более простых задач анализа данных (когда нет естественного порядка поступления наблюдений)
- •и, во-вторых, от анализа пространственных данных, в котором наблюдения зачастую связаны с географическим положением.

Модель временного ряда в общем смысле отражает идею, что близкие во времени наблюдения будут теснее связаны, чем удалённые.

Кроме того, *модели временных рядов зачастую используют однонаправленный порядок по времени* в том смысле, что значения в ряду выражаются в некотором виде через прошлые значения, а не через последующие

Методы анализа временных рядов зачастую делят на два класса: **анализ в частотной области и анализ во временной области.**

- **Первый основывается на спектральном анализе** и с недавних пор вейвлетном анализе, и может рассматриваться в качестве не использующих модели методов анализа, хорошо подходящих для исследований на этапе разведки.
- *Методы анализа во временной области* также имеют безмодельное подмножество, состоящее из кросс-корреляционного анализа и автокорреляционного анализа, но именно здесь появляются частично и полностью определённые модели временных рядов.

Существует несколько методов анализа данных, применимых для временных рядов.

Общее исследование

- •Визуальное изучение графических представлений временных рядов
- Автокорреляционный анализ для изучения зависимостей
- •Спектральный анализ для изучения циклического поведения, не связанного с сезонностью

Описание

- •Разделение компонент: тренд, сезонность, медленно и быстро меняющиеся компоненты, циклическая нерегулярность
- •Простейшие свойства частных распределений

Прогнозирование и предсказание

- •Полноценные статистические модели при стохастическом моделировании для создания альтернативных версий временных рядов, показывающих, что могло бы случиться на произвольных отрезках времени в будущем (предсказание)
- •Упрощённые или полноценные статистические модели для описания вероятные значения временного ряда в ближайшем будущем при известных последних значениях (прогноз)

Модели временных рядов

Как показано Боксом и Дженкинсом, модели временных рядов могут иметь различные формы и представлять различные стохастические процессы.

При моделировании изменений уровня процесса можно выделить три широких класса имеющих практическую ценность:

авторегрессионые модели, интегральные модели и модели скользящего среднего.

Эти три класса линейно зависят от предшествующих данных. На их основе построены модели <u>авторегрессионного скользящего среднего</u> (<u>Autoregressive Moving Average</u>, <u>ARMA</u>) и <u>авторегрессионного интегрированного скользящего среднего</u> (<u>Autoregressive Integrated Moving Average</u>, <u>ARIMA</u>).

Модели временных рядов

- •Эти модели в свою очередь обобщает модель авторегрессионного дробноинтегрированного скользящего среднего (<u>autoregressive fractionally integrated moving average</u>, <u>ARFIMA</u>).
- •Расширения моделей на случаи, когда данные представляются не скалярно, а векторно, называют моделями многомерных временных рядов. Для таких моделей в сокращённых названиях появляется буква «v» от слова «vector».
- •Существуют расширения моделей на случай, когда исследуемый временной ряд является ведомым для некоторого «вынуждающего» ряда (который, однако, может не быть причиной возникновения исследуемого ряда).
- Отличие от многомерного ряда заключается в том, что вынуждающий ряд может быть детерминированным или управляться исследователем, проводящим эксперимент.
- •Для таких моделей в сокращении появляется буква «х» от «exogenous» (экзогенный, вызываемый внешними причинами).

Модели временных рядов

- •Нелинейная зависимость уровня ряда от предыдущих точек интересна, отчасти из-за возможности генерации хаотических временных рядов. Но главным всё же является то, что опытные исследования указывают на превосходство прогнозов, полученных от нелинейных моделей, над прогнозами линейных моделей.
- •Среди прочих типов нелинейных моделей временных рядов можно выделить модели, описывающие изменения дисперсии ряда со временем (гетероскедатичность).
- •Такие модели называют моделями авторегрессионной условной гетероскедастичности (<u>AutoRegressive Conditional Heteroscedasticity</u>, <u>ARCH</u>). К ним относится большое количество моделей: GARCH, TARCH, EGARCH, FIGARCH, CGARCH и др.

Модели временных рядов

- •В этих моделях изменения дисперсии связывают с ближайшими предшествующими данными.
- •Противовесом такому подходу является представление локально изменчивой дисперсии, при котором дисперсия может быть смоделирована зависящей от отдельного меняющегося со временем процесса, как в бистохастических моделях.
- •В последнее время значительное внимание снискали исследования в области безмодельного анализа и методы, основанные на вейвлетных преобразованиях (например локально стационарные вейвлеты) в частности.
- •Методы многомасштабного анализа разлагают заданный временной ряд на составные части, чтобы показать зависимость от времени с разным масштабом.